TidyESI:

Make discipline statistics more easy in R

王敏杰

2020年6月13日

四川师范大学

初衷

现实需求

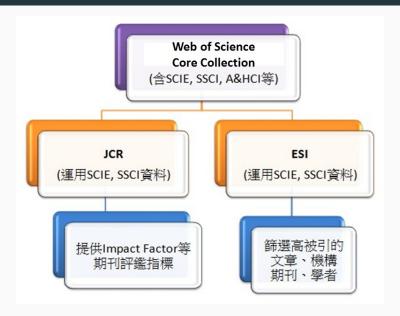
在做科研信息分析报告的时候,换位思考,对方肯定想获取一些信息,比如:

- 机构的科研产出多少?影响力多少?
- 与同行比较,孰高孰低?
- 是否进入 ESI 学科?哪些进入?同行都哪些进入了?
- 现在阈值线多少?距离阈值线还差多少?
- 高被引论文多少?高被引贡献了多少?
- 二级机构的贡献比是多少?
- 更多需求...

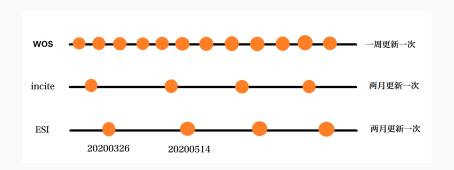
面临挑战

- 回答以上问题,需要
 - 多个数据源
 - 多个评价指标
 - 多个评估对象(多个机构、多个学科)
 - 说明:评价机制越来越多元
- 带来的挑战
 - 多个数据集,如何整合?
 - 多个指标值,如何计量?
 - 思考: 如何提高工作有效性、准确性

学科评价用到的数据源

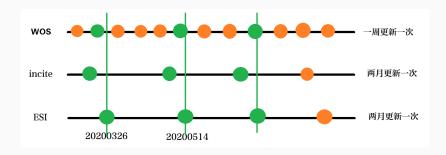


现实困境



三个库更新时间不同步!如何合并?

可接受的办法



三个库合并(下载办法参考附录):

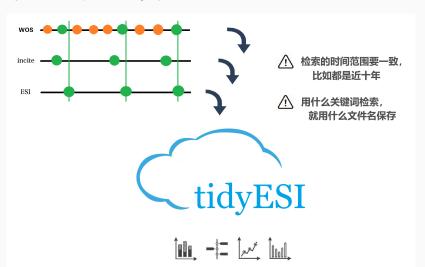
- ESI 库:包含 (ESI 学科阈值线,高被引论文)
- incite 库:包含某机构历年科研产出和影响力
- WOS 库:包含某机构科研产出和影响力的题录清单

一旦 ESI 库更新, 立马下载另两个库

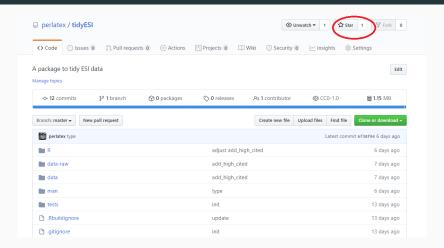
思考与 tidyESI

tidyESI

tidyESI 是一个 R 语言宏包,主要用于规整 ESI 和 incites 等数据格式,想法来源bibliometrix宏包



tidyESI



- https://github.com/perlatex/tidyESI
- devtools::install_github("perlatex/tidyESI")

函数

功能 1: 读取 incites 数据

```
library(tidyESI)
library(tidyverse)
# 一个机构
df <- read_incites(
    "./data_incites/Sichuan Normal University.csv")
```

univ	discipline	year	n_paper	n_cited
Sichuan Normal University	Physics	2000	6	104
Sichuan Normal University	Physics	2001	6	100
Sichuan Normal University	Physics	2002	22	303
Sichuan Normal University	Physics	2003	30	179
Sichuan Normal University	Physics	2004	26	242

功能 1: 读取 incites 数据

```
# 多个机构
dt <- here::here("data_incites_normal_univ") %>%
fs::dir_ls(regexp = "\\.csv$") %>%
read_incites()
```

univ	n_paper	n_cited
Anhui Normal University	5309	79687
Beijing Normal University	33283	511749
Capital Normal University	8167	92554
Central China Normal University	12420	242724
Chongqing Normal University	2942	28601

功能 2: 读取高被引论文数据

```
# 单个机构
sicnu <- read_highcited(
   "./data_highcited/Sichuan Normal University.xlsx")
```

year	authors
2014	QIAO, JS;KONG, XH;HU, ZX;YANG, F;JI, W
2010	SUN, CL;LI, H;YU, DG;YU, MA;ZHOU, XA;LU, XY;HUANG, K;Z
2015	ZHANG, XC;ZHAO, GP;FANGOHR, H;LIU, JP;XIA, WX;XIA, J;N
2015	LIANG, S;WANG, T;HU, X;LUO, J;LI, W;WU, X;DUAN, Y;JIN, F
2018	HAN, JR;LIU, ZC;MA, YJ;CUI, GW;XIE, FY;WANG, FX;WU, YP
2016	WEI, GW

功能 2: 读取高被引论文数据

```
# 多个机构
hc <- here::here("data_highcited_normal_univ") %>%
fs::dir_ls(regexp = "\\.xlsx$") %>%
tidyESI::read_highcited()
```

year	authors
2014	QIAO, JS;KONG, XH;HU, ZX;YANG, F;JI, W
2010	SUN, CL;LI, H;YU, DG;YU, MA;ZHOU, XA;LU, XY;HUANG
2015	ZHANG, XC;ZHAO, GP;FANGOHR, H;LIU, JP;XIA, WX;XIA
2015	LIANG, S;WANG, T;HU, X;LUO, J;LI, W;WU, X;DUAN, Y;J
2018	HAN, JR;LIU, ZC;MA, YJ;CUI, GW;XIE, FY;WANG, FX;WU
2016	WEI, GW

15

功能 3: 读取进入 ESI 前百分之一学科的机构清单

```
# 多个机构

top <- here::here("data_isEnter_normal_univ") %>%
  fs::dir_ls(regexp = "\\.xlsx$") %>%
  tidyESI::read_top_one_percent()
```

univ	discipline	top_papers	is_enter_top
Anhui Normal University	Chemistry	20	TRUE
Beijing Normal University	${\sf Environment/Ecology}$	53	TRUE
Beijing Normal University	Geosciences	72	TRUE
Beijing Normal University	Chemistry	35	TRUE

演示数据

为了演示方便, 我这里只选取部分

```
df_sub <- df %>% dplyr::filter(
  year %in% c("2018", "2019"),
  discipline %in% c("Physics", "Chemistry")
)
df_sub
```

univ	discipline	year	n_paper	n_cited
Sichuan Normal University	Physics	2018	62	396
Sichuan Normal University	Physics	2019	82	90
Sichuan Normal University	Chemistry	2018	91	1656
Sichuan Normal University	Chemistry	2019	102	471

功能 4: 添加高被引论文信息

discipline	year	n_paper	n_cited	n_paper_high	n_cited_high
Physics	2018	62	396	2	151
Physics	2019	82	90	1	18
Chemistry	2018	91	1656	11	908
Chemistry	2019	102	471	8	193

功能 4: 添加高被引论文信息

discipline	year	n_paper	n_cited	n_paper_high	n_cited_high
Physics	2018	62	396	6	2303
Physics	2019	82	90	6	2303
Chemistry	2018	91	1656	21	1656
Chemistry	2019	102	471	21	1656

功能 5: 添加阈值

tidyESI 宏包会定期更新最新阈值

```
# 添加最新的阈值线
df_sub %>%
   add_esi_threshold(discipline, date = "last") %>%
   select(-univ)
```

discipline	year	n_paper	n_cited	20200514
Physics	2018	62	396	21050
Physics	2019	82	90	21050
Chemistry	2018	91	1656	8188
Chemistry	2019	102	471	8188

功能 5: 添加阈值

```
# 添加全部的阈值线
df_sub %>%
   add_esi_threshold(discipline, date = "all") %>%
   select(-univ)
```

discipline	year	n_paper	n_cited	20200326	20200514
Physics	2018	62	396	21325	21050
Physics	2019	82	90	21325	21050
Chemistry	2018	91	1656	8502	8188
Chemistry	2019	102	471	8502	8188

功能 5: 添加阈值

```
# 添加指定日期的阈值线

df_sub %>%

add_esi_threshold(discipline,

date = c("20200326", "20200514")) %>%

select(-univ)
```

discipline	year	n_paper	n_cited	20200326	20200514
Physics	2018	62	396	21325	21050
Physics	2019	82	90	21325	21050
Chemistry	2018	91	1656	8502	8188
Chemistry	2019	102	471	8502	8188

功能 6: 添加学科信息

```
# 添加是否进入 ESI 前百分之一学科
df_sub %>%
add_is_enter_top(univ, discipline, source = top)
#> Please make sure the source information is up to date.
```

univ	discipline	year	n_paper	n_cited	is_enter_
Sichuan Normal University	Physics	2018	62	396	NA
Sichuan Normal University	Physics	2019	82	90	NA
Sichuan Normal University	Chemistry	2018	91	1656	NA
Sichuan Normal University	Chemistry	2019	102	471	NA

功能 7: 汉化学校名

univ	discipline	year
Sichuan Normal University	Physics	2018
Sichuan Normal University	Physics	2019
Sichuan Normal University	Chemistry	2018
Sichuan Normal University	Chemistry	2019

```
df_sub %>% select(-starts_with("n_")) %>%
    tidyESI::add_univ_name_cn(univ)
```

univ	discipline	year	univ_cn
Sichuan Normal University	Physics	2018	四川师范大学
Sichuan Normal University	Physics	2019	四川师范大学
Sichuan Normal University	Chemistry	2018	四川师范大学
Sichuan Normal University	Chemistry	2019	四川师范大学

功能 8: 汉化学科名

univ	discipline	year	n_paper	n_cited
Sichuan Normal University	Physics	2018	62	396
Sichuan Normal University	Physics	2019	82	90
Sichuan Normal University	Chemistry	2018	91	1656
Sichuan Normal University	Chemistry	2019	102	471

df_sub %>% add_discipline_cn(discipline)

univ	discipline	year	n_paper	n_cited	discipline
Sichuan Normal University	Physics	2018	62	396	物理学
Sichuan Normal University	Physics	2019	82	90	物理学
Sichuan Normal University	Chemistry	2018	91	1656	化学
Sichuan Normal University	Chemistry	2019	102	471	化学

功能 9: issn 映射到 ESI 学科

id	issn
1	2053-1583
2	2329-7662

```
dt %>% mutate(
  discipline = map_issn_to_esi_discipline(issn)
)
```

id	issn	discipline
1	2053-1583	Materials Science
2	2329-7662	Engineering

功能 10: 二级机构映射

(目前仅对四川师范大学)

```
coll

Sichuan Normal Univ, Coll Geog & Resource Sci,
Sichuan Normal Univ, Coll Geog & Resources Sci,
Sichuan Normal Univ, Coll Geog & Resources,
```

```
tb %>% mutate(
  coll_name = map_addr_to_college_name(coll)
)
```

coll	coll_name
Sichuan Normal Univ, Coll Geog & Resource Sci,	地理与资源科学学院
Sichuan Normal Univ, Coll Geog & Resources Sci,	地理与资源科学学院
Sichuan Normal Univ, Coll Geog & Resources,	地理与资源科学学院

下一步

未来打算

- 解析 WOS 题录
 - parse_title_highcited()
- 解析高被引题录
 - parse_title_wos()
- 用户可添加二级机构的映射关系表
 - import_college_name()

感谢聆听,欢迎批评

38552109@qq.com

附录

ESI 学科阈值线

ESI 学科阈值

近十年,各 ESI 学科被引次数排在前 1% 的作者或机构的最低被引频次

tidyESI

tidyESI 宏包会自动更新最新阈值

incites 数据

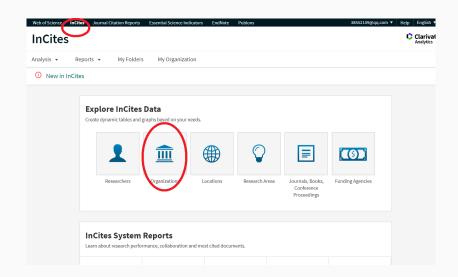
incites 数据

某个机构历年科研产出和影响力等

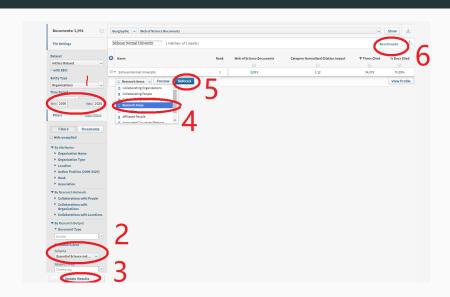
获取办法

- · 点击进入 web of science(SCI), 页面最上面一排 incites
- · 点击菜单第一个 Analysis 下拉选项中的 Organizations
- 设置
 - 选择 Time period 2000 2020
 - 在 By_Research_Output 栏下的 Research Area 选择第二个 Essential Science Indicators
 - 选择 Document Type = Review + Article
 - 更新 Update results
- 检索
 - 输入 sichuan normal university
 - 点击 sichuan normal university 下出现的小框框中选择 Research Areas 后,点击 Refocus
- 下载
 - 点击 Benchmarks 下载(注意要**勾选 Trend Data**,不勾就是汇总表)
 - 重命名 Sichuan Normal University.csv (注意与检索词一致,很重要)
 - 每个学校一张表

incites 数据



incites 数据



高被引论文

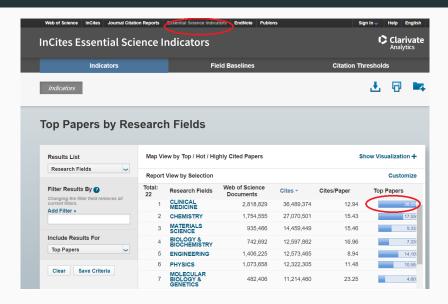
高被引论文

同一年同一个 ESI 学科发表论文的被引次数按由高到 低进行排序, 排在前 1% 的论文

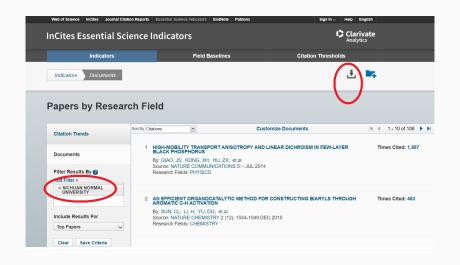
获取方法

- 打开 web of science, 点击 Essential Science Indicators
- 点击页面右边 "Top Papers" 下的进度条,进入高被引论文查询页面
- 点击页面左边 "Add Filter", 选择 "institution", 进入机构高被引论文查询页面
- 检索框中输入 Beijing Normal University, 查询机构高被引论文详情
- 下载 XLS 格式
- 重命名 Beijing Normal University.csv (与检索词一致,很重要)

高被引论文



高被引论文



WoS 题录数据

- 打开 https://www.webofknowledge.com/, 进入核心 合集
- 输入学校全名: 比如 Sichuan Normal University
- 选择"机构扩展"检索
- 选择时间范围: "2010-2020 年"
- 选择 "SCI/SSCI/A&HCI"
- 点击检索
- 文档类型精炼: "Article + Review "
- 一次显示最多 50 条,一次下载最多 500 条
- 选择 "其他类型下载"+ "全记录"+ "win UTF"
- 下载保存